

WGAN-GP 기반 항공 시뮬레이터의 시각적 품질 향상을 위한 원격 감지 이미지 색상 보정 연구



이찬호¹, 이일균²

¹ 서울과학기술대학교 국방인공지능응용학과

² 대한민국 공군 군수사령부 항공소프트웨어지원소

1. 연구 배경 및 목적
2. 관련 연구
3. 연구 방법
4. 연구 결과
5. 결론 및 향후 연구 방향
6. 기대 효과 및 활용 방안
7. 참고문헌

1. 연구 배경 및 목적

□ 항공 시뮬레이터

- 항공 시뮬레이터의 가장 큰 목적은 실제 비행 환경과 가장 유사하도록 구현하는 것
- 항공기의 고도화/첨단화에 따라 실 비행 비용은 갈수록 증가세로 항공 시뮬레이터의 역할은 점차 확대
- 실 비행 전 시뮬레이터 탑승은 필수이며 조종사의 생존성과 교육 훈련, 작전 운용성에 직접적인 영향

□ 시뮬레이터와 충실도(Fidelity)

- 시뮬레이터 몰입감을 위해 높은 충실도(High-Fidelity)가 요구되며 외부시계영상(OTW)는 심미성으로 몰입감 제공



FIG 1. 시뮬레이터 Cockpit 예시



FIG 2. 외부시계영상 예시

1. 연구 배경 및 목적

□ 해외 임무를 위한 신규 지역 추가 소요 증가

- F-15K Red Flag Alaska, Nellis
- KF-16 Pitch Black Darwin
- T-50B Black Eagles Airshow
- P-3C RIMPAC
- 고장/기상 악화/연료 부족 등 비상 상황을 위한 기착지



FIG 3. KF-16 Pitch Black

연합뉴스

공군, 다국적 연합 공중전투훈련 레드플래그 알래스카 참가

레드플래그 알래스카 훈련은 미국 태평양 공군사령부가 주관하는 다국적 연합 공중전투 훈련으로, 우리 공군은 2013년부터 참가해 왔다.

2023. 6. 1.

VNA Voice of America

군산 미 공군기지 “미한일 연합공중훈련 ‘레드 플래그 알래스카’ 실시”

미국 공군이 최근 한국, 일본과 함께 알래스카에서 대비 태세를 위한 연합공중훈련을 펼쳤습니다. 미군은 이 훈련을 통해 동맹, 파트너 간의 상호...

2023. 6. 27.

연합뉴스

공군, UAE 주관 다국적 훈련 '데저트 플래그' 참가

공군, UAE 주관 다국적 훈련 '데저트 플래그' 참가 ... (서울=연합뉴스) 김호준 기자 = 공군은 오는 19일부터 내달 10일까지 아랍에미리트(UAE) 아부다비...

2024. 4. 16.

M 문화일보

공군, “모래알처럼 정밀하고 바람처럼 빠르게”... '2024 데저트 플래그 연합훈련' 성공적 완료

장병들은 중동의 악기상을 뚫고 △저고도 침투 및 화물 투하 △비정상 기지 전술 이·착륙 △전자전 임무 수행 능력 향상 훈련 등으로 다국적군과 작전...

1개월 전

YTN

공군, 19일부터 3주간 UAE에서 열리는 다국적 연합훈련 참가

공군은 오는 19일부터 다음 달 10일까지 아랍에미리트 아부다비에 있는 알 다프라 공...

2024. 4. 16.



FIG 4. 다양한 해외 임무 기사

1. 연구 배경 및 목적

□ 지형 영상

- 지구 표면의 형태와 특징을 시각적으로 표현한 이미지이며, 지형 영상을 얻기 위해 주로 항공 사진과 위성 영상 사용
- 3D 모델과 함께 항공 시뮬레이터의 외부시계영상(OTW) 구현에 필요한 중요 요소로 개발에 가장 기본적이며 제일 넓은 업무 범위

□ 불규칙 지형 영상

- 동일 지역 촬영 시기가 달라 발생하며 일반적으로 계절적 변화나 조명 조건 변화, 구름 유무 등 다양한 사유
- 일관되지 못한 색상은 심미성의 저하로 연결



FIG 5. 지형 영상 예시



FIG 6. 불규칙 지형 영상 예시

1. 연구 배경 및 목적

□ 심미성

- 훈련 조종사들의 몰입도에 직접적인 영향을 주는 요소
- 심미성 향상을 위해 국내/외에서 많은 연구 진행 중

□ 현 지형 영상 개선 절차

- 현재 대부분의 불규칙 지형 영상 개선 절차는 모든 과정에 인적 개입이 필요
- 담당 디자이너에 따라 결과물의 편차 발생 및 상당 시간 소요



FIG 7-1. 경계선 인식




FIG 7-2. 영역 분할



FIG 7-3. 색상 일치화

2. 관련 연구

□ Histogram Matching

- 이미지 처리에서 널리 사용되는 고전적인 기법
- 참조 이미지를 기준으로 타겟(or 소스) 이미지의 히스토그램을 조정하여 두 이미지 간 시각적 특성을 맞춤
- 색상 또는 밝기의 분포를 일치시킴으로 두 이미지가 유사한 특성을 가지도록 만듦

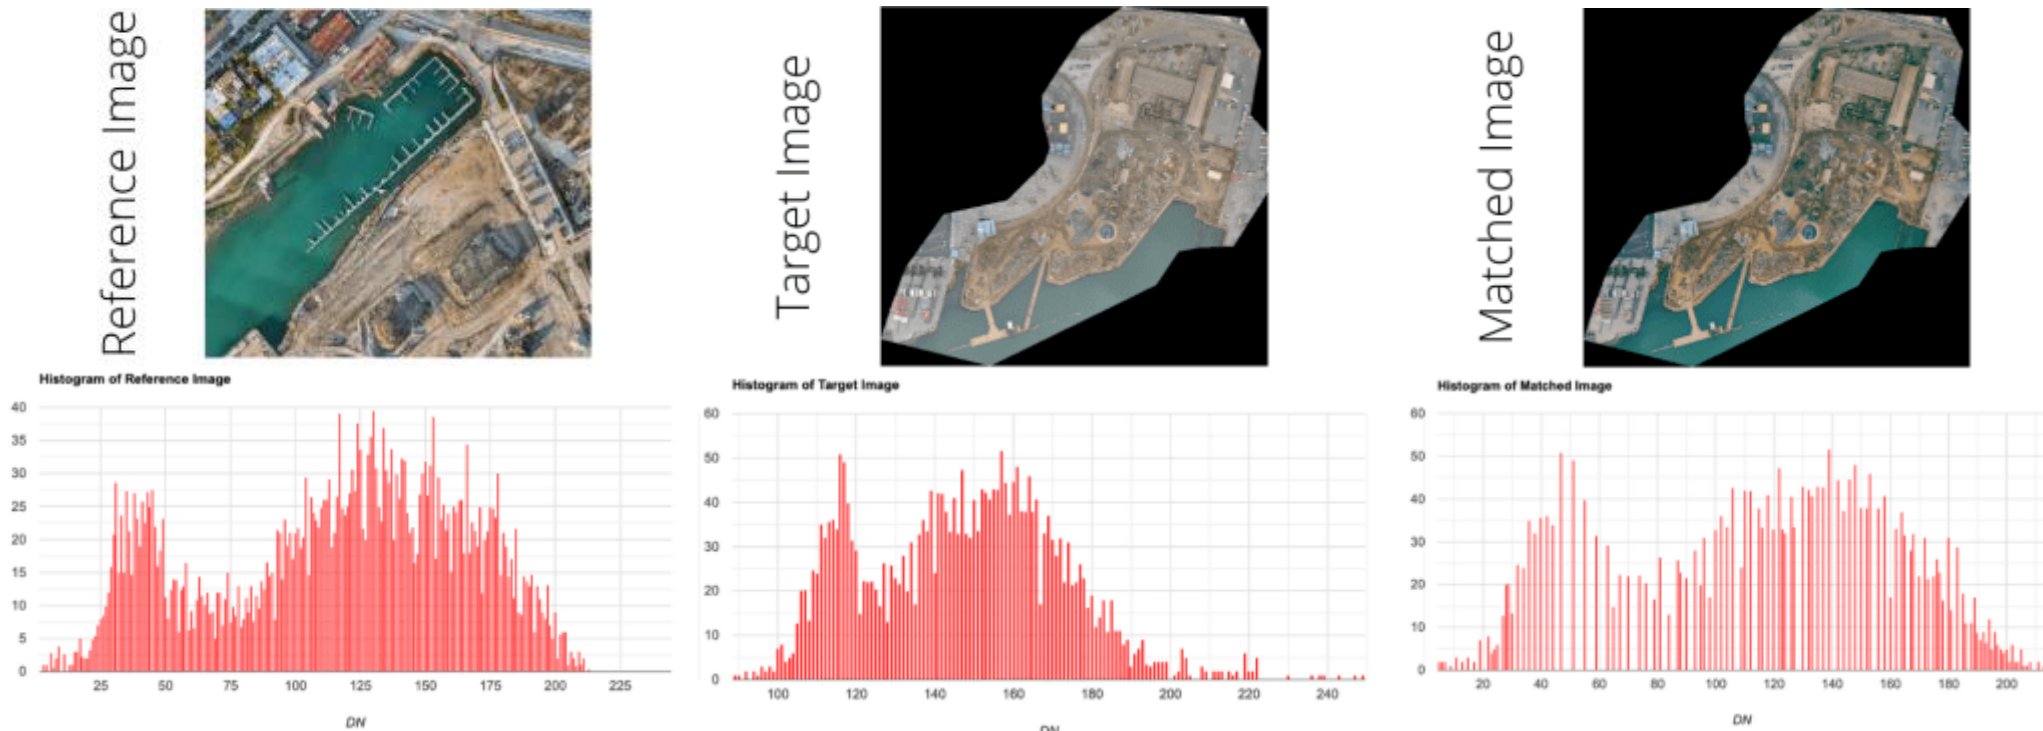


FIG 8. Histogram Matching 예시

2. 관련 연구

□ Histogram Matching의 한계

- 지역적 특성 및 복잡한 이미지 처리
 - 전역적인 색상 분포 조정에 초점을 두기 때문에 이미지의 세부적인 지역적 특성이나 복잡한 텍스처를 제대로 반영하지 못해 중요한 디테일이 손실되거나 왜곡 될 수 있음
- 이미지 간 색상 왜곡 가능성
 - 참조 이미지와 타겟(or 소스) 이미지 간 색상 차이가 클 경우, 히스토그램 매칭이 부자연스러운 색조나 대비를 초래할 수 있어 결과물이 왜곡 될 가능성이 있음




FIG 9. Histogram Matching의 한계 예시

2. 관련 연구

□ Color Transfer

- 한 이미지의 색상 스타일을 다른 이미지에 적용하는 기법
- 이미지의 색상 통계를 계산 후, 타겟(or 소스) 이미지의 색상을 참조 이미지의 색상 통계에 맞춰 변환
 - 색상 통계: 평균, 분산 등
- 특정 색조나 분위기를 다른 이미지로 쉽게 전달 가능

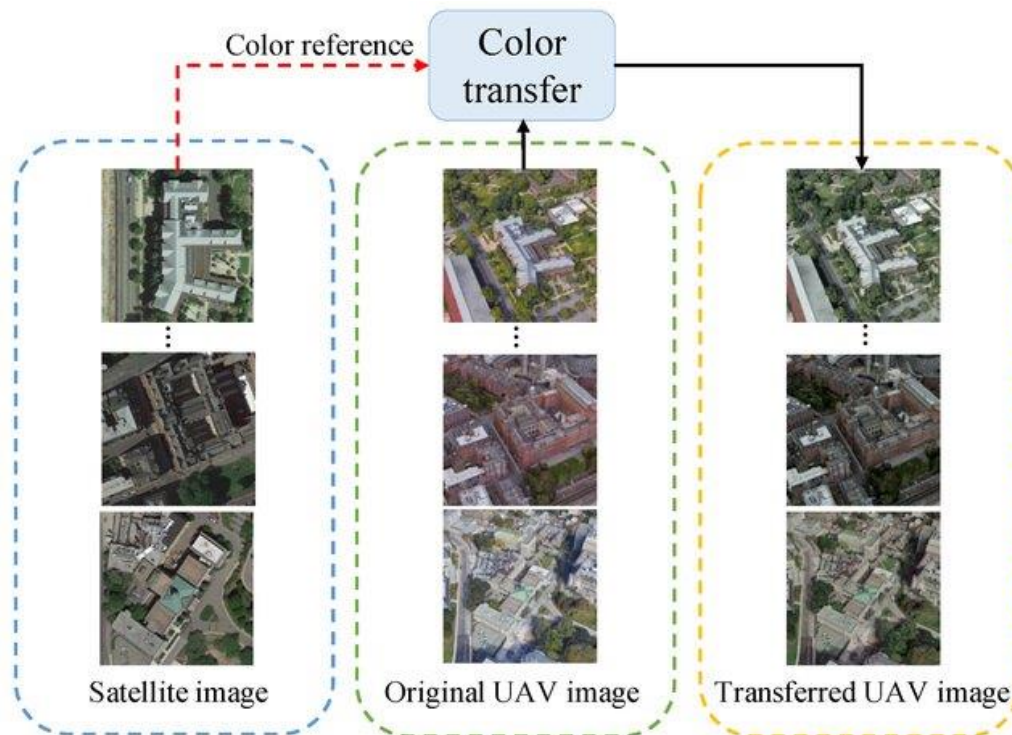


FIG 10. Color Transfer 예시

2. 관련 연구

□ Color Transfer의 한계

- 구조적 특성 및 텍스처 유지의 어려움
 - 색상 통계 조정에 초점을 맞추기 때문에 이미지의 구조적 특성이나 텍스처를 충분히 유지하지 못해, 타겟(or 소스) 이미지의 질감이나 형태가 손실되거나 왜곡 될 수 있음
- 부자연스러운 색상 변환 가능성
 - 두 이미지(참조 이미지, 타겟(or 소스) 이미지)간 색상 차이가 클 경우, 부자연스러운 색상 변환을 하여 결과물이 의도와 다르게 나타날 가능성이 있음




FIG 11. Color Transfer의 한계 예시

2. 관련 연구

□ GAN 기반 색상 보정

- GAN에서 생성자(Generator)는 실제 데이터와 유사한 가짜 데이터 생성
- 판별자(Discriminator)는 가짜 데이터를 잘 구별하도록 적대적 학습
 - 충분한 학습이 되면 실제와 유사한 데이터를 생성
 - 균일한 색상 이미지를 학습하면 생성자는 불규칙한 색상 이미지를 균일한 색상 이미지로 생성 할 수 있음




FIG 12. GAN based Color Correction 예시(상, 생성 사진 / 하, 실제 사진)

2. 관련 연구

□ GAN 기반 색상 보정의 한계

- 불안정한 학습 과정
 - 모드 붕괴(mode collapse): 학습 과정에서 생성자와 판별자의 균형이 이뤄지지 않을 때, 생성된 결과가 다양하지 않고 편향되는 문제 발생
 - 과적합 문제: 대규모의 훈련 데이터로 학습하지 못하는 경우 특정한 특징에 과적합 될 수 있으며, 이로 인해 일반화 성능이 떨어질 수 있음
 - 손실 함수: KL 발산과 JS 발산을 사용하지만 두 분포가 겹치지 않는 경우 무한대 또는 미분 불가능한 값을 반환하여 학습이 불안정해짐




FIG 13. 모드 붕괴(mode collapse) 예시(좌, 이상적인 출력 / 우, 모드 붕괴)

2. 관련 연구

□ WGAN-GP 기반 색상 보정 제안

- GAN의 문제점 해결
 - WGAN은 손실 함수를 Wasserstein 거리를 기반으로 수정하여 생성자와 판별자 간 차이를 더 잘 반영
 - Wasserstein 거리: 두 확률 분포 간 차이를 측정하는 거리 함수로 두 분포가 겹치지 않는 경우에도 유효한 거리를 제공하여 기존 GAN의 손실 함수보다 안정적인 학습 가능
- WGAN-GP
 - WGAN은 Wasserstein 거리를 사용하지만, 가중치 클리핑(weight clipping)을 통해 K-Lipschitz 조건을 강제 적용하여 표현력 제한 및 최적화 불안정 문제가 있음
 - K-Lipchitz 조건: 함수의 기울기가 특정 값을 넘지 않도록 제한하여 입력 변화에 따른 출력의 급격한 변동을 막는 조건으로, 이 조건을 만족하면 판별자가 생성된 데이터와 실제 데이터 간의 차이를 안정적이고 일관되게 측정
 - WGAN-GP는 Gradient Penalty를 도입하여 판별자의 기울기를 1에 가깝게 유지하며 자연스럽게 K-Lipschitz 조건을 만족시켜 학습의 안정성과 효율성을 향상시킴
- 제안한 WGAN-GP 모델을 학습하여 불규칙 지형 영상을 보다 일관된 색상과 텍스처를 가진 지형 영상 생성

3. 연구 방법 - 실험 환경

□ 하드웨어

- GPU: NVIDIA DGX A100(80GB) X 3 (서울과기대 슈퍼컴퓨터 데이터센터)

□ 소프트웨어

- 운영 체제: Linux
- 언어 및 프레임 워크: Python, TensorFlow, PyTorch
- 모델: WGAN-GP

□ 하이퍼 파라미터

• 모델 하이퍼 파라미터 설정

- Train : Val : Test = 7: 2 : 1
- batch_size: 128
- n_critic(판별자 모델의 업데이트 횟수): 5
- lambda_gp(Gradient Penalty의 가중치): 10
- epochs: 10

• Adam 하이퍼 파라미터 설정

- learning_rate: $1e-4$
- beta_1 (Adam의 첫 번째 모멘텀 파라미터): 0.5
- beta_2 (Adam의 두 번째 모멘텀 파라미터): 0.9

3. 연구 방법 - 데이터 셋

□ BigEarthNet-S2

- 수집 기간: 2017년 6월~2018년 5월
- 수집 지역: 유럽 10개국(오스트리아, 벨기에, 핀란드, 아일랜드, 코소보, 리투아니아, 룩셈부르크, 포르투갈, 세르비아, 스위스)
- 수집 타일: 115개 타일
- 데이터 구성: 549,488장의 Sentinel-2 이미지 패치 (압축 시 59GB)
- 밴드: 12개의 밴드(특정 파장 범위의 전자기 복사를 감지하는 센서의 분광 영역)
 - B01: 해안 에어로졸; 60m
 - B02: 파란색; 10m
 - B03: 녹색; 10m
 - B04: 빨간색; 10m
 - B05: 식생의 붉은색 가장자리; 20m
 - B06: 식생의 붉은색 가장자리; 20m
 - B07: 식생의 붉은색 가장자리; 20m
 - B08: 근적외선; 10m
 - B09: 수증기; 60m
 - B11: SWIR; 20m
 - B12: SWIR; 20m
 - B8A: 좁은 NIR; 20m

3. 연구 방법 - 데이터 셋

□ B02, B03, B04를 결합하여 RGB 이미지로 변환하여 참조 이미지로 사용(549,488 장)




FIG 14. BigEarthNet-S2의 B02, B03, B04를 결합하여 RGB 이미지로 변환

3. 연구 방법 - 데이터 셋

□ RGB 이미지를 무작위로 분할하고 색상, 명암 등을 조정하여 타겟 이미지로 사용 (549,488 장)




FIG 15. RGB 이미지를 무작위로 조정한 데이터 셋

3. 연구 방법 - 모델

□ WGAN-GP 기반 색상 보정 모델 아키텍처

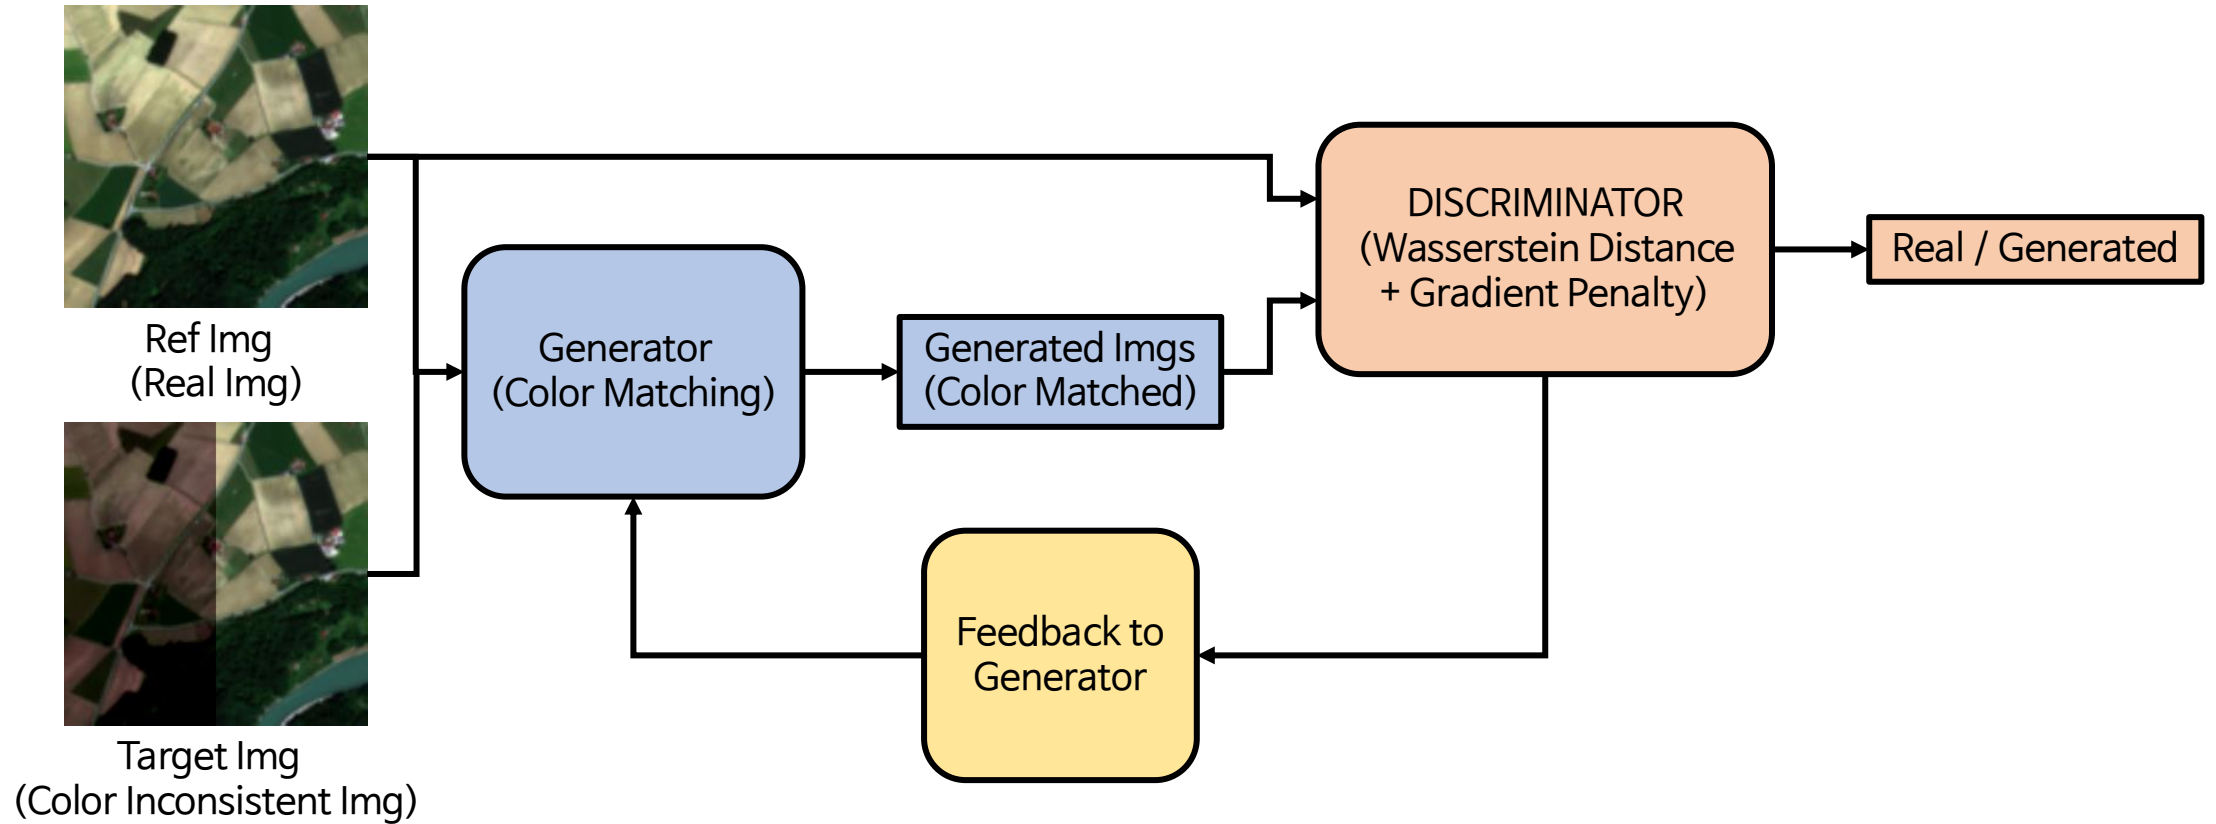


FIG 16. WGAN-GP 기반 색상 보정 모델 아키텍처

3. 연구 방법 - 모델

□ 생성자(Generator)

- 생성자(Generator)는 타겟 이미지의 색상 불규칙성을 참조 이미지의 색상에 맞춰 조정하여 이미지 생성
- 색상 불규칙 이미지의 색상을 참조 이미지의 색상에 맞추는 것이 목표

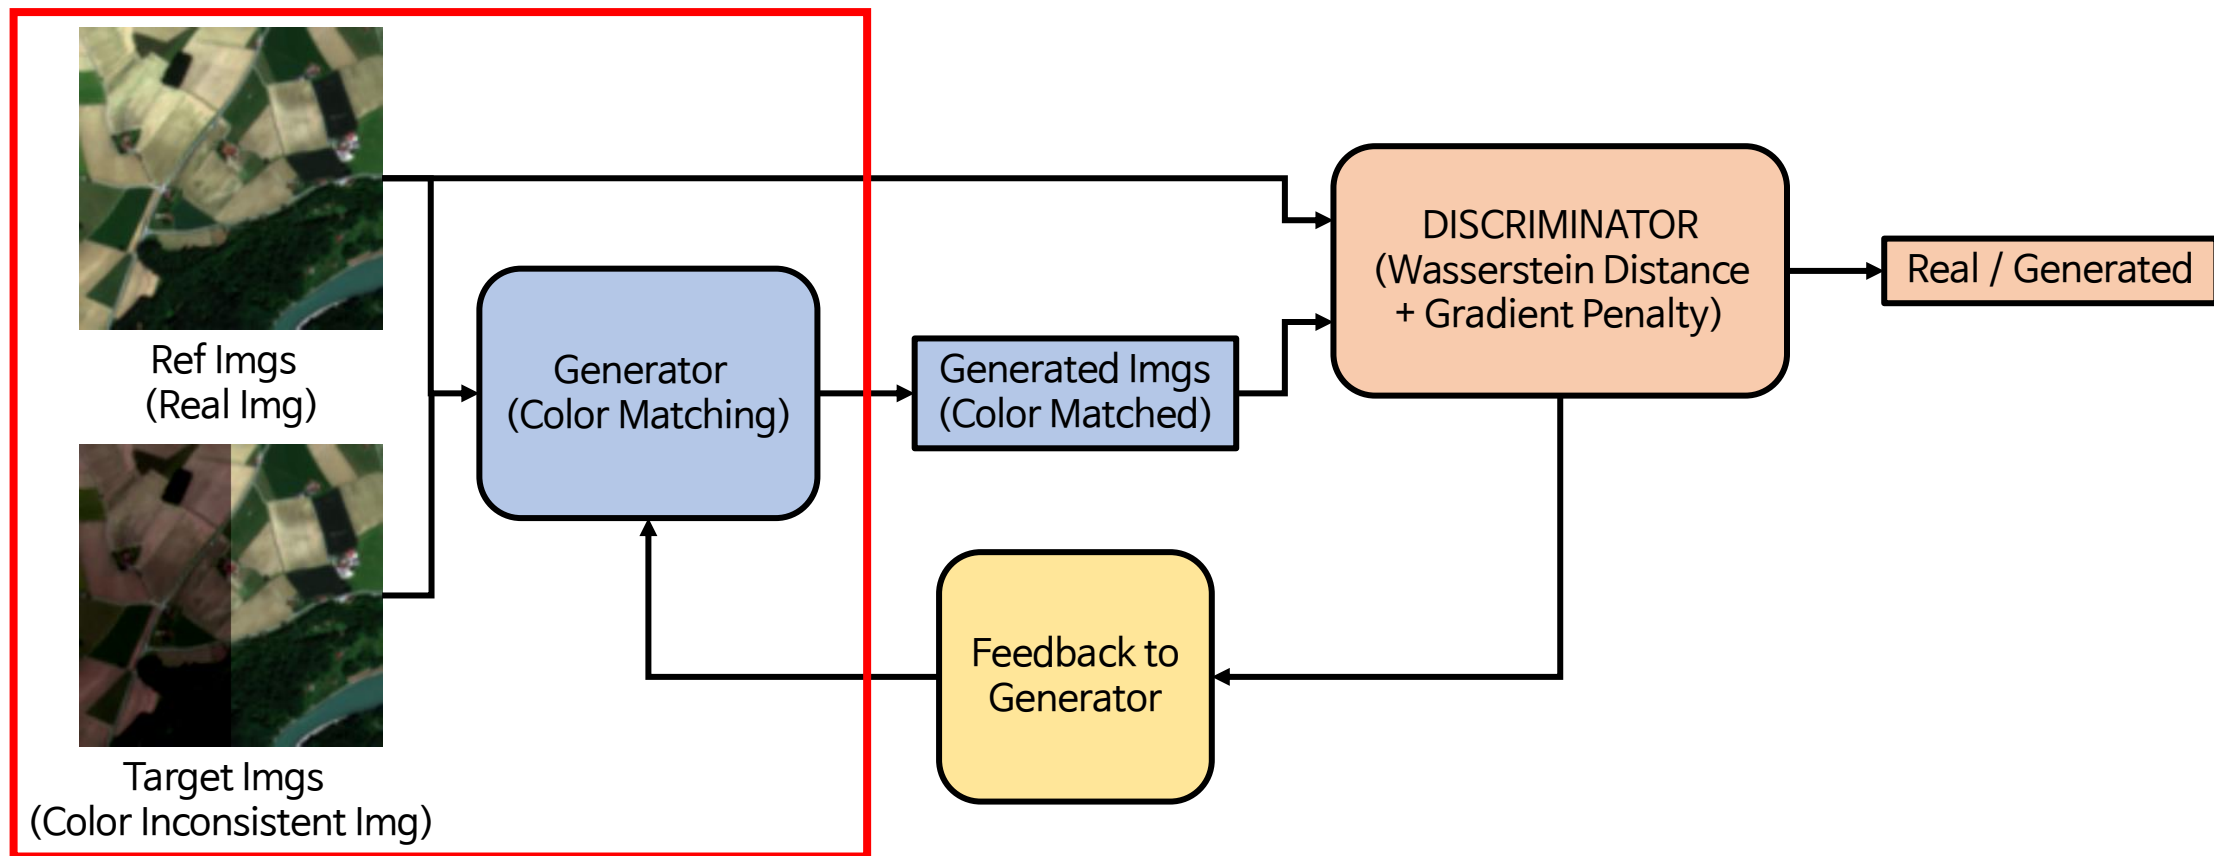


FIG 16. WGAN-GP 기반 색상 보정 모델 아키텍처

3. 연구 방법 - 모델

□ 판별자(Discriminator)

- 판별자(Discriminator)는 입력 받은 이미지가 실제 이미지(참조 이미지)인지, 아니면 생성자(Generator)가 생성한 가짜 이미지(Generated Imgs)인지를 평가
- 판별자는 이미지 간의 차이를 Wasserstein 거리로 계산하여, 이 거리를 최소화 하는 것이 생성자의 목표
- Gradient Penalty는 이미지의 Gradient Norm을 1에 가깝게 유지하여 판별자의 학습 안정성과 일반화 성능을 향상

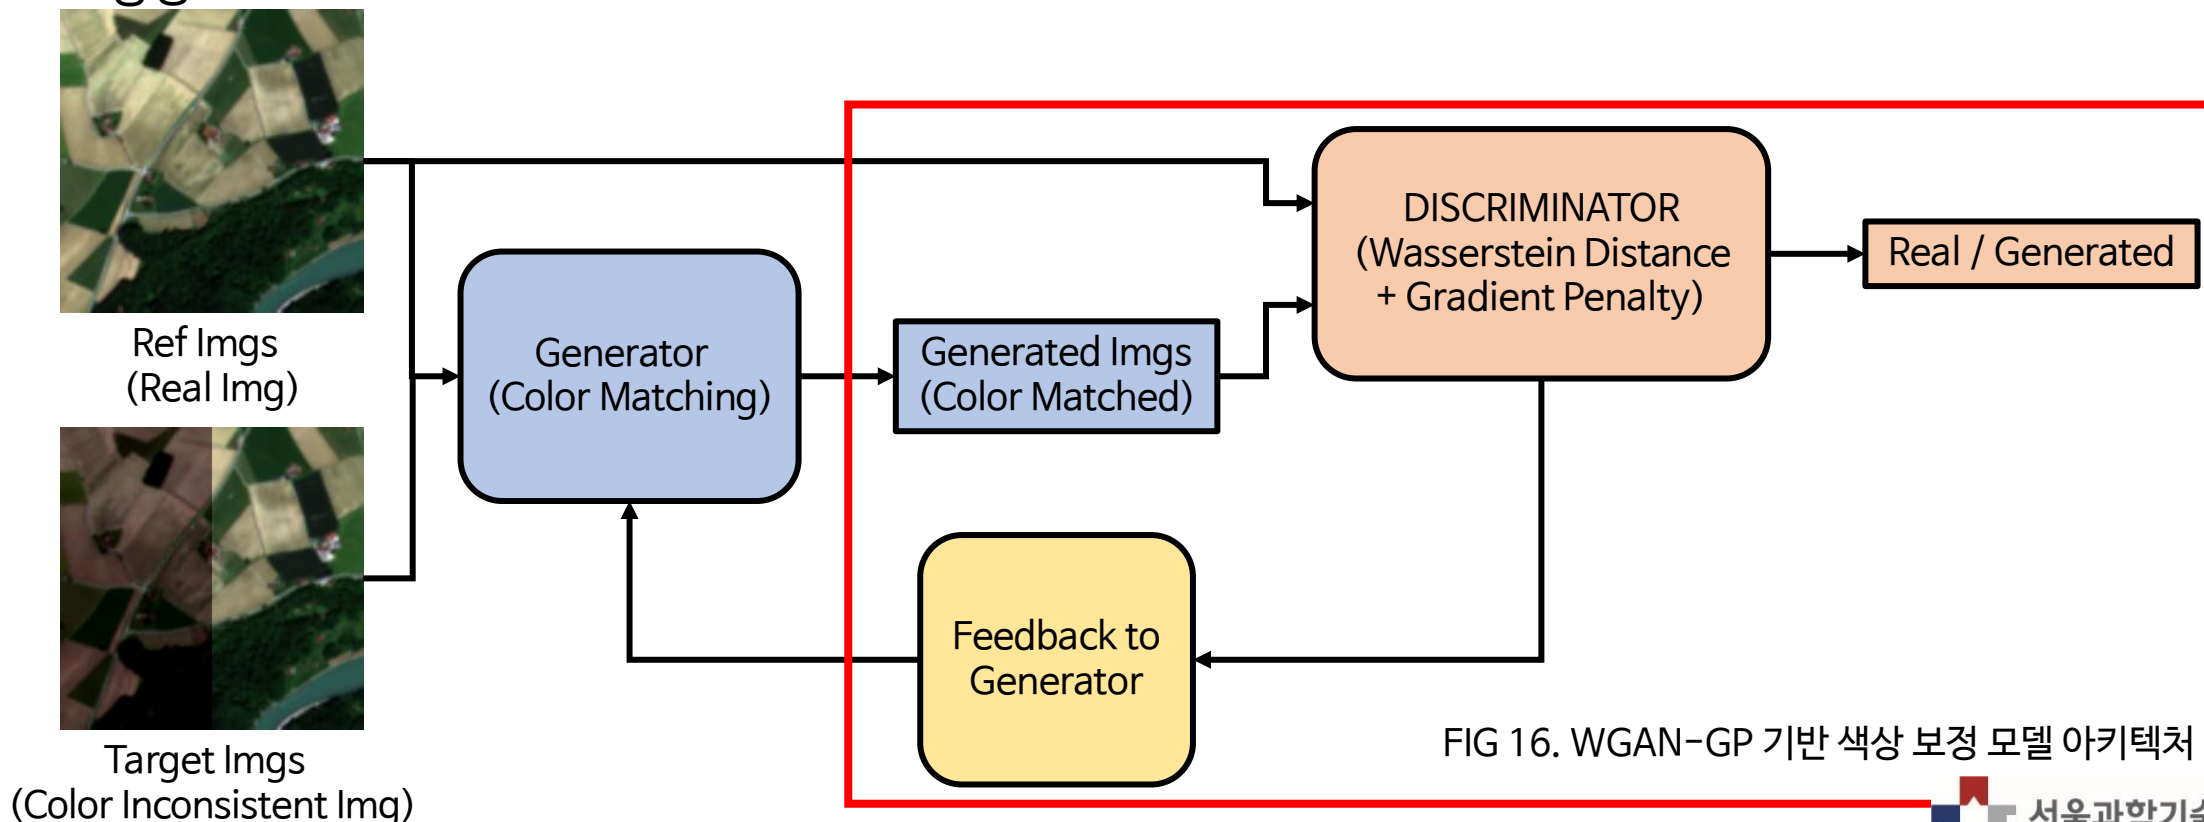


FIG 16. WGAN-GP 기반 색상 보정 모델 아키텍처

4. 연구 결과 - Train Loss & Val Loss

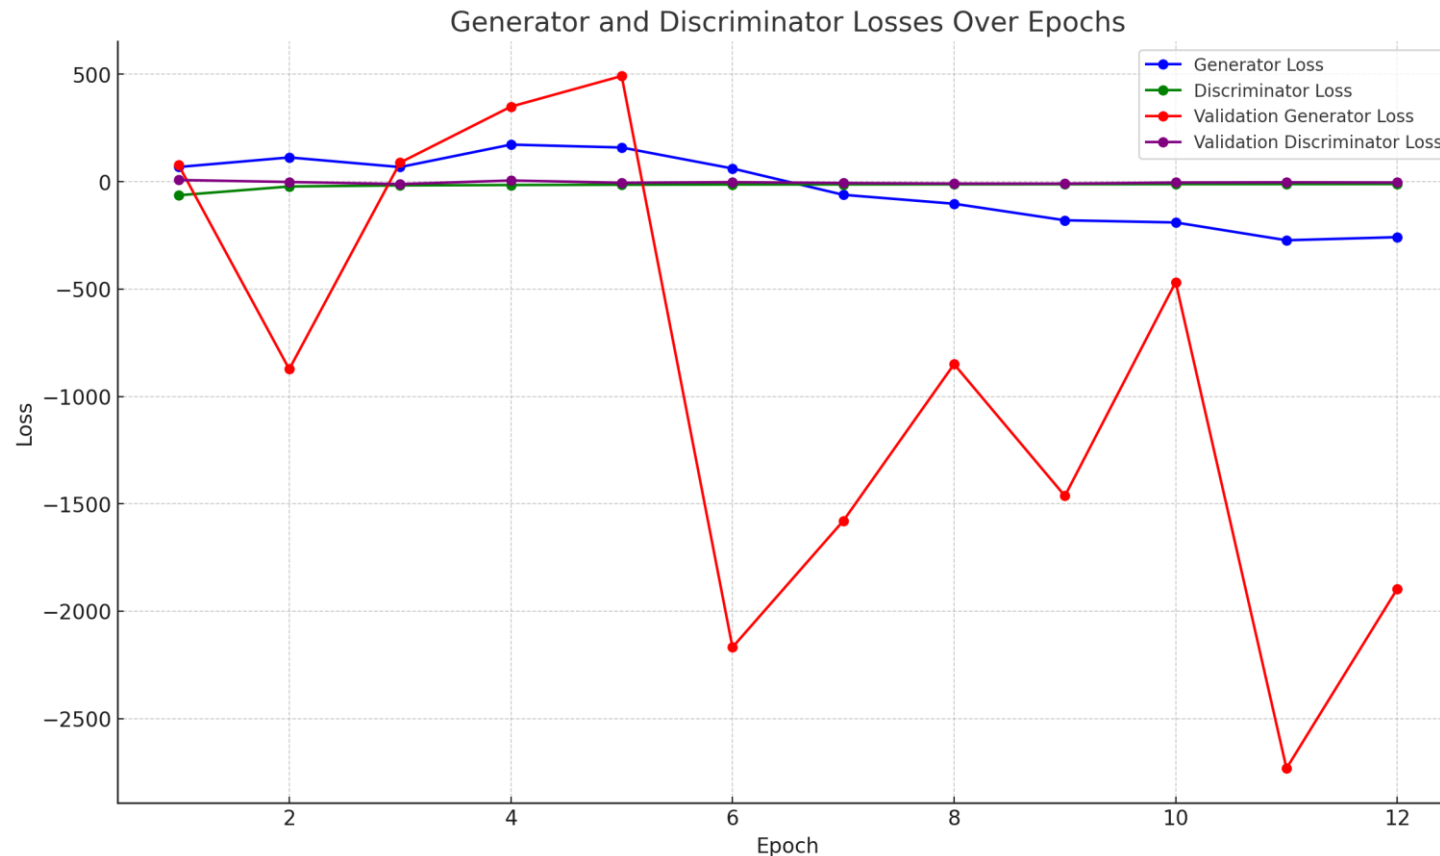


FIG 17. Train Loss & Validation Loss

- **Generator Loss**: 생성자가 판별자를 속이는 정도를 나타내며, 값이 낮을 경우 생성자가 잘 학습되는 것을 의미
- **Validation Generator Loss**: 검증 데이터에서 생성자의 성능 평가, 값이 크게 변동할 경우 과적합 또는 일반화 문제 의미
- **Discriminator Loss**: 실제와 가짜 데이터를 구분하는 능력을 나타내며, 값이 낮을 경우 판별자가 잘 학습되는 것을 의미
- **Validation Discriminator Loss**: 검증 데이터에서 성능을 평가, 값이 높을 경우 일반화 능력이 부족

4. 연구 결과 - 테스트 이미지로 평가

- 학습이 진행될수록 모델의 성능이 개선되어 생성된 이미지가 불규칙한 색감을 지속적인 학습을 통해 점차 규칙적으로 변할 수 있음




FIG 18-1. 테스트 이미지 원본

FIG 18-2. epoch 1 모델로
생성한 이미지

FIG 18-3. epoch 10 모델로
생성한 이미지

FIG 18-4. epoch 20 모델로
생성한 이미지

FIG 18-5. Ground Truth

4. 연구 결과 - 테스트 이미지로 평가

- 학습이 진행될수록 모델의 성능이 개선되어 생성된 이미지가 원본 이미지의 텍스처를 선명하게 재현 할 수 있음

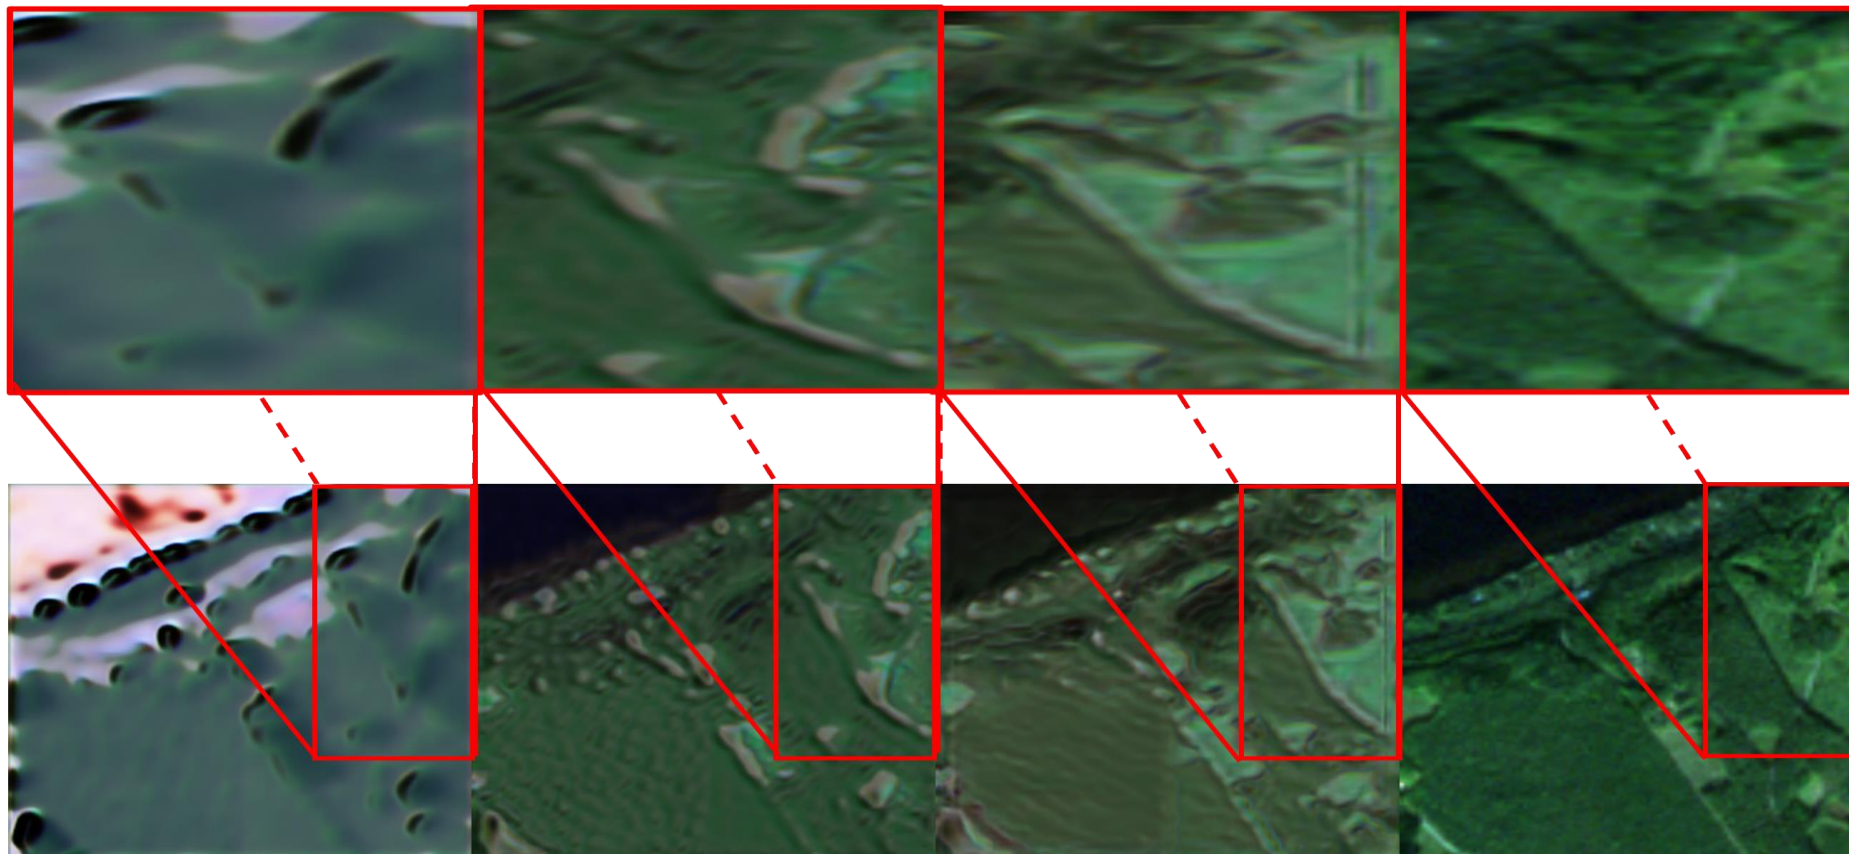


FIG 19-1. epoch 1 모델로
생성한 이미지

FIG 19-2. epoch 10 모델로
생성한 이미지

FIG 19-3. epoch 20 모델로
생성한 이미지

FIG 19-4. Ground Truth

4. 연구 결과 - 히스토그램, 컬러 트랜스퍼와 비교

□ 제안된 모델을 히스토그램과 컬러 트랜스퍼 기법과 비교하였음




FIG 7-1. 테스트 이미지 원본




FIG 20-2. 히스토그램




FIG 20-3. 컬러 트랜스퍼




FIG 20-4. epoch 1 모델로
생성한 이미지




FIG 20-5. epoch 10 모델로
생성한 이미지




FIG 20-6. epoch 20 모델로
생성한 이미지




FIG 20-7. Ground Truth

4. 연구 결과

- Epoch 10 모델 성능이 전반적으로 가장 우수하다는 것을 알 수 있었으며, 모든 지표에서 최적의 성능을 보임
- 제안된 방법이 Epoch 1에서부터 점차 성능이 향상되다가 Epoch 10에서 최고 성능을 기록한 후 Epoch 20에서 성능이 약간 감소되거나 유지되는 경향을 보임

	Histogram	Color Transfer	Proposed (Epoch 1)	Proposed (Epoch 5)	Proposed (Epoch 10)	Proposed (Epoch 20)
PSNR/dB	27.5229	27.495	27.6841	28.5484	28.9298	28.2966
SSIM	0.6949	0.5585	0.4559	0.6739	0.7116	0.6459
CIEDE2000 /Mean ΔE	9.4066	9.8801	26.0101	9.7644	7.3487	9.6674
LPIPS	0.3194	0.1933	0.6318	0.4382	0.3978	0.4005

5. 결론 및 향후 연구 방향

□ 결론

- 본 연구에서는 WGAN-GP 기반 색상 보정 기술을 통해 항공 시뮬레이터의 시각적 품질을 향상시키는 방법 제안
- 실험 결과, 학습이 진행될수록 불규칙한 지형 이미지의 색상이 일관되게 보정되며, 원본의 텍스처 또한 점차 재현
- 충분한 학습이 되면 항공 시뮬레이터의 시각적 품질을 향상시켜 조종사의 훈련 몰입도와 현 지형 영상 개선 절차의 효율성을 높일 수 있음

□ 향후 연구 방향

- 충분한 학습 후 다양한 지형 데이터와 조건을 포함하여 전이 학습으로 모델의 일반화 능력 강화
- 지역의 계절 특성을 고려하여 해당 계절별 이미지 생성 (ex. 겨울철 눈 덮인 지형 영상)
- 사용자의 요구를 받아 이미지 생성 (ex. 안개 낀 지형 영상 생성)

6. 기대 효과 및 활용 방안

□ 기대 효과

- 훈련 몰입도 및 기대효과
 - 시각적 콘텐츠의 심미성 향상으로 인한 훈련 조종사들의 몰입도 증가 및 피로도 저하
- 시간/비용적 측면
 - 수작업 처리 방식에 비해 시간과 비용을 절감하여 운영 효율성 증대
 - 신규 지역 추가 소요에 대한 빠르고 효율적인 대응 가능
- 확장성
 - 다양한 지형 영상을 기반으로 한 훈련 콘텐츠 생성으로 확장 가능

□ 활용 방안

- 기존 관심 지역(AOI) 업데이트 지형 영상 개선
 - 납품 이후 진행된 업데이트로 서로 다른 지형 영상들이 혼재되어 있으나 전체적으로 일관된 색상으로 개선 가능
 - 이기종간 Source Data 공유 증가
- 다기종의 해외 임무용 사전 훈련 DB 신속 제공
 - 다양한 해외 임무와 다양한 기종을 위해 사전 훈련용 DB를 신속 제공하여 임무 준비 시간 단축
 - 충분한 사전 훈련으로 다양한 훈련 시나리오 숙지 및 비상 상황 대응 가능

7. 참고문헌

1. JY. Rau, NY. Chen and LC. Chen. True Orthophoto Generation of Built-Up Areas Using Multi-View Images. *Photogramm. Eng. Remote Sens.*, vol. 68, no.6, p. 581–588. 2002.
2. Z. Li, Z. Jing, X. Yang and S. Sun. Color transfer based remote sensing image fusion using non-separable wavelet frame transform. *Pattern Recognition Letters.*, vol. 26, p. 2006–2014. 2005
3. C. Fabbri, M. J. Islam and J. Sattar, "Enhancing Underwater Imagery Using Generative Adversarial Networks," *2018 IEEE International Conference on Robotics and Automation (ICRA)*, Brisbane, QLD, Australia, 2018, pp. 7159–7165, doi: 10.1109/ICRA.2018.8460552.
4. M. Arjovsky, S. Chintala, and L. Bottou. Wasserstein gan. arXiv preprint arXiv:1701.07875, 2017.
5. I. Gulrajani, F. Ahmed, M. Arjovsky, V. Dumoulin and A. Courville. Improved Training of Wasserstein GANs. arXiv preprint arXiv:1704.00028, 2017.

Q&A

THANKS FOR YOUR ATTENTION



이찬호¹, 이일균²

¹ 서울과학기술대학교 국방인공지능응용학과

² 대한민국 공군 군수사령부 항공소프트웨어지원소